點樣砌一套會自己搵你嘅 AI 助理系統

唔係砌一個 chatbot，係砌一個**會主動查、主動出聲**嘅系統。 以下係我部 8GB Mac 上真跑緊嘅架構、每一步點做、每個位踩過咩坑。 所有指令同路徑都係實測可用嘅。

砌到咩

- 5 個 agent，各管一塊，context 互唔污染
- 33 個自動排程，日夜自己查
- Telegram 做控制台：得閒唔嘈你，有事先講
- 每個 agent 有自己嘅記憶、技能、工作目錄

三個原則

- **分工唔好貪**：一個 agent 唔做所有事
- **唔好意思係關鍵**：寧靜過勤力
- **要有 ledger**：邊個 job 做過乜，要查得到

0 · 成個架構

```
Telegram  ──►  Hermes Gateway（常駐服務 launchd）
                  │
                  ├──► profile: personal    （你本人個助理、創作、研究）
                  ├──► profile: company     （公司嘢、營運）
                  ├──► profile: trading     （交易 / 行情）
                  ├──► profile: sports      （運動數據）
                  └──► profile: ios         （iOS 裝置專用）

每個 profile 各自有：
  config.yaml         模型 / provider / 啟用咗嘅 toolset
  cron/jobs.json      排程定義（每個 profile 一套）
  cron/executions.db  執行收據（查「上次跑咗乜」用呢個）
  memories/           MEMORY.md（環境事實）+ USER.md（你嘅偏好）
  skills/             做流程用嘅 skill（唔使每次重新解釋）
  sessions/           對話歷史

腳本層（跨 profile 共用）：
  project/openclaw/shared/scripts/       共用嘅 shell / python
  project/hermes/projects//        每個項目自己嘅 scripts、logs
```

1 · 裝起個 Gateway

1.1 互動安裝

```
hermes setup                # 互動精靈：模型、provider、工具、記憶
hermes auth                 # 登入 provider（認證會 pool 埋，唔會每日失效）
hermes model                # 揀預設模型 / provider
hermes fallback             # 設 fallback chain：主模型掛咗自動接落去
```

我而家用緊三個 provider 輪住試：`claude-subscription-directsdk-experimental`（Opus）、`minimax-cn`、`deepseek`。 排程入面最重嘅工作（例如研究報告）就係靠呢條 fallback chain 頂住。

1.2 接 Telegram

```
hermes gateway setup        # 填 bot token、chat id、對話模式
hermes gateway install      # 裝成 launchd 背景服務（重開機自動返）
hermes gateway start
hermes gateway status
hermes doctor               # 一次過檢查依賴、配置、常見問題
```

Delivery 一定要明寫。每個排程都要自己指定送去邊個帳號 / 對話， 唔指定就會沿用上一個 session 嘅路線 —— 我試過幾次訊息漏咗去群組。落場 job 嘅 `deliver` 同 `failure_deliver` 我都會寫死（例：`telegram:96691420`）。

2 · 切 profile：一個 agent 一個 profile

Hermes 每個 profile 係一個**完全獨立**嘅 agent：自己嘅 config、記憶、技能、排程、session。 路徑：`~/.hermes/profiles/<profile>/`

Profile	做乜	排程
`personal`	你本人個助理：創作、研究、發布、呢個 reel	16 個（17 個定義）
`company`	公司 / 營運相關	7 個
`trading`	交易、行情、監控	9 個
`sports`	運動數據	1 個
`ios`	iOS 裝置專用（語音、裝置動作）	—

合共 33 個啟用緊嘅排程。分 profile 嘅真正好處：context 細咗、權限細咗、撞唔到。 一個 agent 乜都做嘅話，記憶會污染，模型會乱諗。

2.1 點叫某個 profile

```
hermes -p personal --provider claude-subscription-directsdk-experimental -m opus -z "做乜"
hermes -p trading   -z "睇下今日倉位"
```

2.2 記憶同技能

檔案	放乜
`memories/MEMORY.md`	環境事實、工具限制、做事方式（每個 session 都注入，字符有上限，要精簡）
`memories/USER.md`	你嘅身份、偏好、語言、表達要求
`skills/<name>/SKILL.md`	做流程用嘅步驟（下次直接叫個名就識做）
`sessions/`	每個對話嘅完整紀錄，要查「上次我哋講過乜」用呢度

> **記憶要短。**MEMORY.md 每個 session 都會全文注入，寫太多會頂爆預算， 舊嘅嘢要定期整理走，唔係越多越好。流程同做法寫入 skill，唔好塞入記憶。

3 · 排程：系統嘅工作量度

排程定義喺 `~/.hermes/profiles/<profile>/cron/jobs.json`。一個 job 大概係咁：

```
{
  "id": "efd8851c678e",
  "name": "Heartbeat v3 — Every 2h",
  "script": "oc-d6026293-heartbeat-v3.sh",
  "no_agent": true,
  "schedule": { "kind": "cron", "expr": "0 5-22 * * *" },
  "deliver": "telegram:96691420",
  "failure_deliver": "telegram:96691420",
  "timezone": "Asia/Hong_Kong",
  "enabled": true,
  "state": "scheduled",
  "last_status": "ok",
  "repeat": { "completed": 66 }
}
```

兩種玩法：

- **script 型**（`no_agent: true`）：直接跑 shell/python，慳 token、快、唔靠模型。
- **agent turn 型**：有 prompt，由 agent 思考後做，適合要判斷、寫作、研究。

3.1 常用指令

```
hermes cron list                    # 睇晒所有 job
hermes cron create                  # 新增（互動）
hermes cron edit <id>               # 改
hermes cron run <id>                # 即刻跑一次
hermes cron pause <id> / resume <id>
hermes cron runs                    # 執行收據：上次幾點跑、outcome 係乜
hermes cron incidents               # 連續失敗嘅 job
hermes cron status                  # scheduler 生死
hermes cron doctor
```

3.2 查真相：唔好信 log，信 receipts

```
sqlite3 ~/.hermes/cron/executions.db "select job_id,status,started_at from runs order by rowid des
c limit 10;"
```

曾經踩過：一個 job 三個模型同時卡死。 研究 pipeline 逐個 provider 輪住試，嗰日三個都卡足 11 分鐘被 watchdog 殺死，浪費咗 33 分鐘先報錯。 修法唔係「再試多次」，係**收緊 timeout**：正常跑 3 分鐘，就將上限設 300 秒（而唔係 600）， 壞就早啲壞，好過拖到天黑。

4 · 跨 profile 叫 agent：one-shot

寫嘢嘅 pipeline 好常見要「叫另一個 agent 幫手做一件大事」。我有一支共用腳本做橋樑：

```
project/openclaw/shared/scripts/hermes_oneshot.sh <profile> <model> <prompt-file>

# 例子
hermes_oneshot.sh personal anthropic/claude-opus-5-5 /tmp/prompt.txt
```

佢做嘅嘢：

1. 將舊式 model id 映射成 Hermes 嘅 provider + model
2. 設好 `HERMES_HOME`（`~/project/hermes`）同 `HOME`
3. 行一次 agent turn，`-z` 帶 prompt，結果印喺 stdout

舊 model id	Hermes provider / model
anthropic/claude-opus-5-5	claude-subscription-directsdk-experimental / opus
anthropic/claude-sonnet-5-5	claude-subscription-directsdk-experimental / sonnet
minimax/*	minimax-cn / *
deepseek/*	deepseek / *

4.1 一個真實例子：每日研究

```
project/hermes/projects/stepflow-marketing/scripts/
  research-brainstorm.sh   # 叫 3 個模型輪住試，任何一個成功就收工
  research-digest.py       # 合併、去重、打分
  research-config.env      # AGENT_TIMEOUT、model 順序、逐個限制
  logs/research.log        # 每次 attempt 嘅耗時、exit code
```

5 · 知識庫：Obsidian 做長期記憶

記憶檔放「環境事實」，但要睇得返嘅嘢（研究筆記、概念、腳本）我放 Obsidian vault：

```
~/Library/Mobile Documents/iCloud~md~obsidian/Documents/Knowledge Base/
  Index.md            # 自動生成嘅索引（唔好手改，會被覆蓋）
  AI Posts/           # 我自己嘅筆記：文章、概念、腳本
    Articles/  Concepts/  Scripts/
  AI Posts.base       # Obsidian Bases：文章 / 概念 / 腳本 三個 view
```

> **分清楚邊啲係自動生成、邊啲係自己寫。** 索引類檔案（Index.md、By-Tag.md、By-Topic.md）係工具生成嘅，手改會被覆蓋；自己嘅內容放另一棵樹（我放 `AI Posts/`），兩邊唔會打架。

6 · 加埋自己把聲同內容（可選但好值）

影片 / 音頻呢啲要真人味嘅嘢，我用 VoiceStudio 嘅本地 API（`127.0.0.1:3900`）：

```
POST /generate   form: profile_id, text, language=yue, speed, class_temperature
POST /profiles   form: name, ref_text, ref_audio (建立 voice profile)
POST /profiles/<id>/attestation  {"basis":"own_voice"}
```

- 參考錄音要**用自己把聲**錄，最好 10 秒以內（有情緒、夾英文嘅句子最好）。
- 用 phoneme 標音（CMU）處理英文詞，但要**逐個詞驗**：有啲詞 phoneme 反而更差。
- Whisper 當驗證工具得，**唔好當評分員**：佢連你自己講嘅英文都聽錯。

7 · 維運 checklist

事項	點做
睇 job 真相	`hermes cron runs / incidents`；`executions.db` 係唯一真相
睇記憶體	`vm_stat`
檢查配置	`hermes doctor / hermes dump`
備份	`hermes backup`
查對話	`hermes sessions list`
改行為	`hermes tools`（邊個平台用邊個 `tool`）
接外部服務	`hermes connectors / mcp / skills`

7.1 8GB Mac 嘅硬限制

記憶體係你第一個樽頸。語音克隆處理 19 秒參考音要約 2.1 GB RAM，我部機只剩 1.3 GB 時直接 HTTP 500（`ReferenceEncodeMemoryError`），而且 `flush-memory` 救唔到。 解法：參考音剪到 ≤10 秒、一次只跑一件重嘢、唔好同時開 render + whisper + 模型。

7.2 通知唔好重複

排程撞埋一齊會同一分鐘send 好幾次同一個 alert。我用一個 mkdir lock 做互斥： 搶到 lock 先發通知，搶唔到就靜默退出。呢招救過我一次（2 分鐘內收到 7 條重複 alert）。

7.3 唔好信 SQLite 舊狀態

退役咗嘅系統個 state db 會 freeze 喺停嗰日，睇落似有資料其實係舊嘅。 每個數字都要搵第二個來源交叉驗證（例如 git log、實際檔案、API 實測）， 先好寫入任何對外嘅嘢。

8 · 一頁 checklist

STEP 1

定清楚佢要主動做乜

寫低：監察邊啲嘢、幾時算有事、咩要通知你、咩唔好嘈你。呢步唔做，後面全部白做。

STEP 2

裝 Hermes，起 Gateway，接 Telegram

hermes setup → hermes gateway setup → hermes gateway install → 確認 status。

STEP 3

切 profile

每個 agent 一個 profile：config、記憶、技能、排程、session 全部獨立。

STEP 4

砌排程

先由一個 script 型 job 做起；delivery 同 failure_deliver 一定寫死。

STEP 5

寫 ledger

每個 job 跑完留低紀錄；用 hermes cron runs 查得到。

STEP 6

逐步加規則

由「每日一次」開始，跑一個星期冇亂出聲，再加密。

STEP 7

寫低你唔想要乜

AI 最易死喺「太勤力」。寧靜係功能，唔係缺陷。

> **成個系統最花時間嘅唔係寫 prompt**，係決定 **佢幾時唔好嘈你**，同埋決定每個 job 失敗之後你點知。 嗰兩樣寫低、寫實，個系統先算得係你嘅。

---

ai.__.life · 內容係我自己部機實測返嚟嘅做法，指令同路徑照抄得，但記得改返你自己嘅路徑。